PROYECTO FINAL · MACHINE LEARNING

Food AI Recommender

Recomendación semántica de platos según preferencias, restricciones y lenguaje natural.

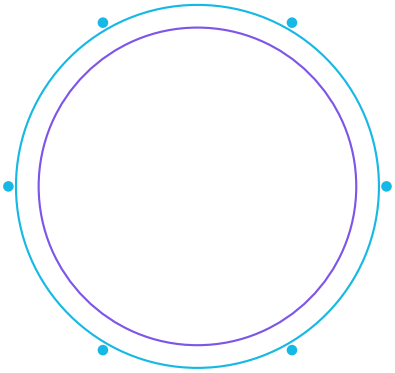
Una implementación funcional para web, kiosko y aplicación de meseros: recibe una frase, aplica seguridad determinista y entrega un top-3 explicable.

80	100	3
PLATOS	CONSULTAS ANOTADAS	RESULTADOS VISIBLES

RESULTADO PRINCIPAL

La línea base obtiene 0.6121 en prueba y el modelo híbrido 0.4727. La comparación se presenta de forma honesta: el sistema funciona, pero el embedding todavía debe mejorar su ordenamiento en este dataset sintético.

Informe preparado para la presentación individual · 2026



01 / PROBLEMA Y OBJETIVO

Problema y objetivo

Los menús digitales tradicionales obligan al cliente a navegar por categorías, leer descripciones y aplicar filtros manuales. La experiencia se vuelve lenta cuando la persona tiene restricciones dietéticas, alergias, preferencias de sabor o un presupuesto concreto.

El objetivo es implementar un sistema que reciba una solicitud en lenguaje natural, por texto o voz, y devuelva los tres platos disponibles más relevantes respetando las restricciones registradas del restaurante.

PREGUNTA EXPERIMENTAL

¿La recuperación semántica de platos mejora la precisión de las primeras recomendaciones frente a una búsqueda tradicional ordenada por popularidad?

02 / ALCANCE FUNCIONAL Y ARQUITECTURA

Alcance funcional y arquitectura

El sistema demuestra la funcionalidad principal solicitada por la asignatura, sin intentar construir toda la plataforma POS. El foco evaluable es la comprensión de la consulta y la recuperación segura de platos.

ENTRADA DEL CLIENTE	BACKEND FASTAPI	RESULTADO VISIBLE
Texto o voz en frontend	Parser + filtro seguro + embeddings + ranking híbrido	Top-3, explicación, aviso de seguridad
Web · kiosko · meseros	Catálogo CSV + índice vectorial	Respuesta JSON y carrito simulado

SEGURIDAD PRIMERO

Las restricciones de disponibilidad y alérgenos se resuelven con reglas deterministas antes del ranking. La IA interpreta el lenguaje natural y calcula relevancia; no decide por sí sola si un plato es médicamente seguro.

03 / DATASET Y PREPARACIÓN

Dataset y preparación

El dataset es sintético y reproducible porque el restaurante todavía no dispone de un historial público de pedidos. El generador mantiene la semilla 20261010 y produce un menú amplio para probar consultas naturales variadas.

ELEMENTO	DESCRIPCIÓN
Menú	80 platos con nombre, descripción, ingredientes, categoría, precio, dietas, alérgenos, picante, disponibilidad, tiempo, calorías, proteína y popularidad.
Consultas	100 solicitudes en español con variaciones coloquiales, restricciones, rangos de precio y casos sin coincidencia segura.
Particiones	20 de ajuste de pesos, 20 de validación y 60 de prueba. De estas últimas, 55 se puntúan y 5 son pruebas operativas de seguridad.
Anotación	Cada consulta contiene identificadores de platos relevantes y el indicador scored para separar ranking de operación segura.
Reproducibilidad	backend/scripts/generate_dataset.py con semilla fija 20261010.

La preparación normaliza acentos y expresiones frecuentes, extrae restricciones estructuradas y construye un texto enriquecido por plato para el encoder multilingüe.

04 / MODELO Y LÍNEA BASE

Modelo y línea base

El modelo reutilizado es sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2 mediante FastEmbed y ONNX Runtime. No se realiza fine-tuning: cada plato y la consulta se transforman en embeddings y se comparan con similitud coseno.

PASO	FLUJO DE INFERENCIA
01	Interpretar la consulta en español y extraer dietas, alérgenos, proteína, picante, categoría y precio.
02	Eliminar del catálogo los platos no disponibles o incompatibles con restricciones de seguridad.
03	Calcular similitud semántica entre la consulta y los candidatos restantes.
04	Reordenar con 55% semántica, 25% coincidencia estructurada y 20% popularidad.
05	Entregar las tres primeras opciones con explicación basada en los datos reales del catálogo.

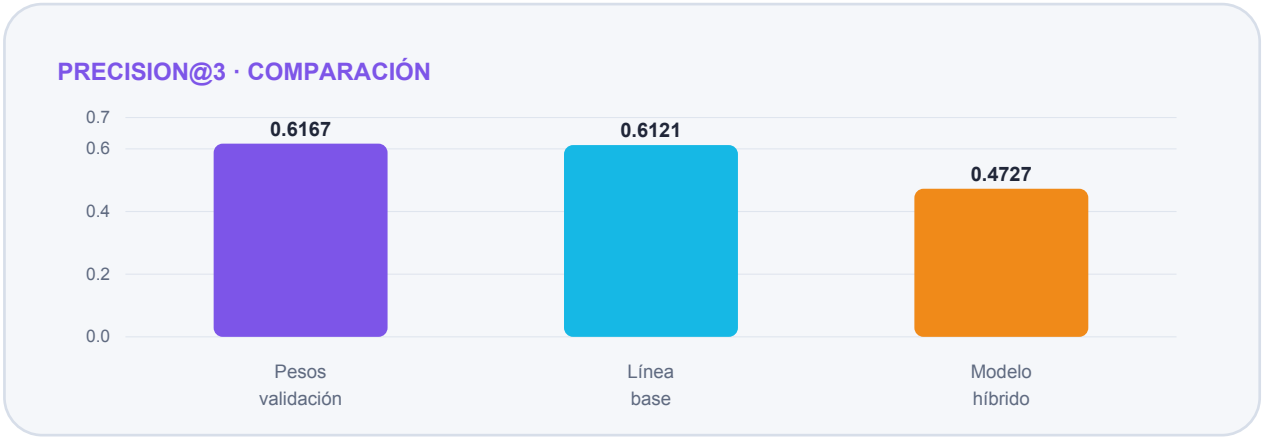
La línea base usa exactamente los mismos filtros de disponibilidad y seguridad y ordena los candidatos por popularidad. La comparación es justa: ambos sistemas reciben el mismo conjunto elegible.

05 / MÉTRICA Y VALIDACIÓN

Métrica y validación

La métrica primaria es Precision@3: la cantidad de platos relevantes que aparecen dentro de las tres primeras recomendaciones dividida entre 3. Es adecuada porque la interfaz muestra tres opciones y el objetivo operativo es recuperar candidatos útiles en esa primera pantalla.

SPLIT	CONSULTAS	SISTEMA	PRECISION@3
Validación	20	Pesos seleccionados	0.6167
Prueba	55	Línea base: filtros + popularidad	0.6121
Prueba	55	Recomendador híbrido	0.4727



LECTURA HONESTA

Los pesos 0.55 / 0.25 / 0.20 se eligieron únicamente con validación. La prueba final no se utilizó para ajustar parámetros. En este dataset sintético la línea base supera al modelo; se reporta y se analiza como una limitación, no como un resultado oculto.

06 / ANÁLISIS DE ERRORES

Análisis de errores

TIPO	CONSULTA	RESULTADO OBSERVADO	LECTURA TÉCNICA
Acierto del modelo	Busco fideos con verduras	Recupera noodles con tofu, pasta vegetal y pasta con garbanzos.	La semántica encuentra platos aunque no todos usen la palabra exacta pasta.
Base superior	Sin gluten y sin soya	La línea base prioriza platos populares compatibles.	El embedding conserva candidatos parecidos, pero el orden por popularidad resulta mejor.
Seguridad	Alergia a pescado y quiero salmón	No devuelve recomendaciones.	El filtro determinista bloquea la contradicción antes del ranking.

07 / BACKEND, FRONTEND Y SEGURIDAD

Backend, frontend y seguridad

COMPONENTE	IMPLEMENTACIÓN
Backend	FastAPI con /api/health, /api/ready, /api/menu, /api/recommend, /api/feedback y /api/evaluation.
Estado del modelo	La interfaz espera /api/ready y distingue loading, ready y error antes de permitir inferencia.
Frontend	Entrada escrita, botón de voz, canal de demostración, restricciones detectadas, top-3, explicaciones y carrito simulado.
Validación	Longitud, canal y top_k; mensajes de error; 12 pruebas automáticas y healthcheck de Docker.
Seguridad	Aviso visible: confirmar ingredientes y contaminación cruzada con el personal; un alérgeno no registrado no garantiza seguridad.

08 / ESCENARIOS PARA LA DEMOSTRACIÓN

Escenarios para la demostración

CASO	ENTRADA	QUÉ SE DEMUESTRA
Válido	Vegetariano, sin lactosa y poco picante	Extracción de restricciones + top-3 explicable.
Difícil	Sin gluten con pollo y menor a Bs 50	Combinación de dieta, ingrediente y presupuesto.
Seguridad	Alergia a pescado y quiero salmón	El filtro rechaza la contradicción antes de la IA.
Inválido	Texto vacío o de un carácter	Validación del backend y mensaje claro al usuario.
Voz	Dictado desde el navegador	Speech API transcribe y reutiliza el mismo endpoint.

DÓNDE ACTÚA LA IA

La IA actúa en la interpretación semántica de la frase y en el cálculo de similitud entre la consulta y los platos. Los filtros de alergias, disponibilidad y validación son reglas deterministas para mantener trazabilidad y seguridad.

09 / PRUEBAS Y EJECUCIÓN

Pruebas y ejecución

La suite automática cubre extracción de restricciones, filtros de seguridad, ausencia de candidatos, comparación con línea base, health check, recomendaciones válidas e inputs inválidos. La última ejecución produjo 12 pruebas exitosas.

Comandos reproducibles:

```
docker compose up --build
Abrir http://localhost:8080
API Swagger: http://localhost:8000/docs
Pruebas: cd backend && MODEL_BACKEND=tfidf pytest -q
```

La primera ejecución necesita conexión a Internet para descargar el modelo preentrenado. Después, el volumen model_cache conserva la caché del encoder.

10 / LIMITACIONES Y TRABAJO FUTURO

Limitaciones y trabajo futuro

- El dataset es sintético y las consultas todavía no representan toda la diversidad de clientes reales.
- La línea base supera al modelo en la prueba actual; se debe mejorar la cobertura semántica y la anotación.
- El historial de pedidos y la personalización individual quedan como extensión posterior.
- El reconocimiento de voz depende de Web Speech API y del navegador.
- La calidad final depende de que el administrador mantenga ingredientes y alérgenos actualizados.

11 / CONCLUSIÓN

Conclusión

La entrega demuestra un flujo completo de Machine Learning aplicado a un sistema de comidas: dataset reproducible, preparación, embeddings, filtros de seguridad, ranking híbrido, línea base, evaluación separada, API, frontend, pruebas y Docker.

MENSAJE FINAL

El producto no intenta adivinar una dieta médica: convierte una intención cotidiana en una búsqueda de menú segura, explicable y lista para integrarse en los canales del restaurante.

12 / REFERENCIAS Y ARTEFACTOS

Referencias y artefactos

ARTEFACTO	UBICACIÓN
Generador y dataset	backend/scripts/generate_dataset.py; backend/data/menu.csv; backend/data/evaluation_queries.jsonl
Modelo e índice	backend/app/recommendation.py; backend/scripts/build_index.py; backend/artifacts/
Evaluación	backend/scripts/tune_weights.py; backend/scripts/evaluate.py; backend/artifacts/evaluation.json
Aplicación	backend/app/main.py; frontend/index.html; frontend/app.js; docker-compose.yml
Modelo preentrenado	sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2 mediante FastEmbed.